

**Санкт-Петербургский политехнический университет
Петра Великого**

Физико-механический институт

Кафедра прикладной математики и информатики

Лабораторная работа №2

По дисциплине: “Математическая статистика”

Тема: «Характеристики положения и рассеяния»

Выполнил студент гр. 5030102/30202:

Куракин А.В.

Преподаватель:

Баженов Александр

Санкт-Петербург

2025

Содержание

Постановка задачи	2
Цели работы:	2
Задачи:	2
Теоретическая часть	3
Реализация	3
Результаты	5
Анализ	6
Вывод	8
Список литературы	10
Github	10

Постановка задачи

Цели работы:

- Изучение вычисления характеристик распределения на основе разных выборок

Задачи:

- Исследовать сходимость выборочных характеристик к теоретическим при росте
- Исследовать оценки характеристик положения на устойчивость к выбросам.

Теоретическая часть

Мы будем генерировать выборки объемом для пяти распределений (нормального, Коши, Лапласа, Пуассона и равномерного). Для каждой выборки необходимо вычислить следующие статистические характеристики:

1. **Выборочное среднее:** $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

2. **Медиана:** $\text{med} = z_{\frac{1}{2}}$

3. **Полусумма экстремальных элементов:**

$$z_R = \frac{x_{\min} + x_{\max}}{2}$$

4. **Полусумма квартилей:** $z_Q = \frac{z_{\frac{1}{4}} + z_{\frac{3}{4}}}{2}$

5. **Усеченное среднее:** z_{tr} (вычисляется как выборочное среднее, но с предварительным отбрасыванием 10% наименьших и 10% наибольших значений).

Генерацию выборок и вычисление характеристик необходимо повторить 1000 раз. По итогам симуляций для каждой характеристики вычисляются:

Среднее: $E(z) = \bar{z}$

Дисперсия: $D(z) = \bar{z}^2 - (\bar{z})^2$

Итоговый результат записывается в формате с соответствующим округлением.

Реализация

Вычисление характеристик:

Для каждой сгенерированной выборки вычислялся набор из пяти характеристик с использованием встроенных функций библиотек `numpy` и `scipy`:

1. **Выборочное среднее:** рассчитывалось функцией `numpy.mean()`.
2. Медиана: рассчитывалась функцией `numpy.median()`.
3. Полусумма экстремальных элементов (z_R): вычислялась по формуле `(numpy.min(data) + numpy.max(data)) / 2`.
4. Полусумма квартилей (z_Q): вычислялась через функцию квантилей `(numpy.quantile(data, 0.25) + numpy.quantile(data, 0.75)) / 2`.
5. Усеченное среднее (z_{tr}): рассчитывалось функцией `scipy.stats.trim_mean(data, 0.1)`, которая автоматически отсекает по 10% отсортированной выборки с каждого края.

Процесс симуляции:

Основной алгоритм программы построен на вложенных циклах. Для каждого из пяти распределений и для каждого объема выборки ($n = 10, 100, 1000$) запускался цикл на 1000 итераций.

Внутри каждой итерации происходило следующее:

1. С помощью методов `rvs` генерировалась случайная выборка заданного размера.
2. Вычислялись 5 описанных выше характеристик, результаты сохранялись во временный двумерный массив `numpy` размером 1000 на 5. После завершения

1000 итераций для данного объема выборки, происходил расчет итоговых оценок:

- Среднее значение каждой характеристики находилось как математическое ожидание по столбцам массива (функция `numpy.mean(axis=0)`).
- Корень из дисперсии $\sqrt{D(z)}$ (стандартное отклонение) находился с помощью функции `numpy.std(axis=0)`.

Итоговые результаты форматировались в виде строк $E(z) \pm \sqrt{D(z)}$ с округлением до двух знаков после запятой и собирались в сводные таблицы с помощью структуры `pandas.DataFrame` для удобного вывода на экран. Для обеспечения воспроизводимости результатов (чтобы при каждом перезапуске скрипта цифры не менялись) в начале программы фиксировалось зерно генератора псевдослучайных чисел `numpy.random.seed()`.

Результаты

1. Нормальное распределение $N(0, 1)$

```
--- Нормальное N(0,1) ---
Нормальное N(0,1)
Выборочное среднее      n=10      n=100      n=1000
Медиана
zR
zQ
ztr
```

	n=10	n=100	n=1000
Выборочное среднее	-0.00 ± 0.31	0.00 ± 0.10	-0.00 ± 0.03
Медиана	-0.01 ± 0.37	0.00 ± 0.12	-0.00 ± 0.04
zR	-0.00 ± 0.43	0.00 ± 0.30	-0.01 ± 0.25
zQ	-0.00 ± 0.34	0.00 ± 0.11	-0.00 ± 0.03
ztr	-0.00 ± 0.32	0.00 ± 0.11	-0.00 ± 0.03

2. Распределение Коши $C(0, 1)$

```
--- Коши C(0,1) ---
Коши C(0,1)
Выборочное среднее      n=10      n=100      n=1000
Медиана
zR
zQ
ztr
```

	n=10	n=100	n=1000
Выборочное среднее	0.47 ± 54.90	-7.39 ± 268.54	0.19 ± 22.95
Медиана	-0.01 ± 0.61	-0.01 ± 0.15	-0.00 ± 0.05
zR	2.40 ± 274.09	-371.12 ± 13412.13	86.87 ± 11129.69
zQ	-0.05 ± 1.00	-0.01 ± 0.24	0.00 ± 0.07
ztr	-0.01 ± 1.15	-0.01 ± 0.23	0.00 ± 0.07

3. Распределение Лапласа $L(0, \frac{1}{\sqrt{2}})$

```

--- Лапласа L(0, 1/sqrt(2)) ---
Лапласа L(0, 1/sqrt(2))

```

	n=10	n=100	n=1000
Выборочное среднее	0.02 ± 0.32	-0.00 ± 0.10	0.00 ± 0.03
Медиана	0.01 ± 0.28	-0.00 ± 0.08	0.00 ± 0.02
zR	0.04 ± 0.64	0.02 ± 0.62	0.00 ± 0.61
zQ	0.01 ± 0.30	-0.00 ± 0.10	-0.00 ± 0.03
ztr	0.01 ± 0.29	-0.00 ± 0.09	-0.00 ± 0.03

4. Распределение Пуассона $P(10)$

```

--- Пуассона P(10) ---
Пуассона P(10)

```

	n=10	n=100	n=1000
Выборочное среднее	10.04 ± 1.04	10.02 ± 0.31	10.00 ± 0.10
Медиана	9.91 ± 1.25	9.87 ± 0.43	10.00 ± 0.05
zR	10.29 ± 1.39	10.92 ± 0.97	11.65 ± 0.83
zQ	9.99 ± 1.11	9.93 ± 0.36	9.99 ± 0.05
ztr	9.98 ± 1.07	9.93 ± 0.32	9.91 ± 0.10

5. Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$

```

--- Равномерное U(-sqrt(3), sqrt(3)) ---
Равномерное U(-sqrt(3), sqrt(3))

```

	n=10	n=100	n=1000
Выборочное среднее	0.00 ± 0.32	0.00 ± 0.10	-0.00 ± 0.03
Медиана	0.01 ± 0.48	0.00 ± 0.17	-0.00 ± 0.05
zR	-0.00 ± 0.22	0.00 ± 0.02	-0.00 ± 0.00
zQ	0.00 ± 0.37	0.00 ± 0.12	-0.00 ± 0.04
ztr	0.00 ± 0.36	0.00 ± 0.12	-0.00 ± 0.04

Анализ

В ходе эксперимента была исследована сходимость статистических характеристик к теоретическим значениям, а также их устойчивость (робастность) к выбросам на примере выборок различного объема ($n = 10, 100, 1000$). На основе полученных результатов можно сделать следующие выводы по каждому распределению:

1. Нормальное распределение $N(0, 1)$

- Все рассматриваемые характеристики корректно стремятся к теоретическому среднему значению 0.0.

- С ростом числа элементов n дисперсия (разброс) для каждой характеристики предсказуемо уменьшается.
- Наилучшей характеристикой положения для нормального распределения является выборочное среднее, так как оно обладает наименьшей дисперсией при больших n .

2. Распределение Коши $C(0, 1)$

- Данное распределение наглядно демонстрирует проблему чувствительности оценок к выбросам. Поскольку у распределения Коши не существует математического ожидания (интеграл расходится) и хвосты распределения очень «тяжелые», выборочное среднее и полусумма экстремальных элементов (z_R) принимают абсолютно случайные значения с гигантской дисперсией при любых n .
- Усеченное среднее (z_{tr}) успешно сходится к 0.0, так как процедура усечения отбрасывает аномальные выбросы на концах выборки.
- Наилучшей и самой робастной (устойчивой) характеристикой здесь выступает медиана, которая показывает наименьшую дисперсию на всех объемах выборки.

3. Распределение Лапласа $L(0, \frac{1}{\sqrt{2}})$

- Все характеристики в среднем сходятся к 0.0.
- Дисперсия полусуммы экстремумов (z_R) практически не убывает с ростом выборки, что делает ее неэффективной оценкой для данного распределения. Усеченное среднее

показывает себя лучше, чем обычное выборочное среднее.

- Наилучший результат сходимости дисперсии и среднего имеет медиана для всех размеров выборок.

4. Распределение Пуассона $P(10)$

- С ростом объема выборки оценка z_R постепенно уходит от теоретического значения 10 (достигая $\sim 11,45$ при $n=1000$).
- При малых выборках ($n = 10, 100$) лучшей оценкой центра является выборочное среднее.
- При росте выборки ($n = 1000$) дисперсия выборочного и усеченного среднего меняется слабо. Наилучшей оценкой становится полусумма квантилей (z_Q), демонстрирующая минимальное отклонение от центра.

5. Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$

- Все характеристики стремятся к теоретическому среднему 0.0.
- Безоговорочно лучшей оценкой выступает полусумма экстремальных элементов (z_R). Особенность равномерного распределения (отсутствие бесконечных хвостов и строго ограниченные рамки) приводит к тому, что дисперсия z_R убывает значительно быстрее остальных оценок (уменьшается квадратично), достигая абсолютного нуля при $n = 1000$.

Вывод

В результате выполнения лабораторной работы были вычислены и проанализированы характеристики

положения и рассеяния для пяти различных распределений (нормального, Коши, Лапласа, Пуассона и равномерного) при объемах выборок $n = 10, 100, 1000$. Анализ полученных результатов, усредненных по 1000 итерациям, позволил сделать следующие выводы:

1. **Сходимость характеристик:** Подтверждена статистическая закономерность: с увеличением числа элементов выборки дисперсия большинства оценок уменьшается, а выборочные характеристики сходятся к своим теоретическим значениям (за исключением характеристик, не устойчивых к выбросам в распределении Коши, и z_R в распределении Пуассона).
2. **Устойчивость к выбросам (робастность):**
Экспериментально доказано, что классическое выборочное среднее не всегда является лучшей оценкой центра распределения. На примере распределения Коши видно, что наличие даже небольшой доли аномальных выбросов полностью искажает выборочное среднее и полусумму экстремальных элементов (z_R). В таких случаях необходимо применять робастные оценки: медиану или усеченное среднее (z_{tr}), которые успешно нивелируют влияние выбросов.
3. **Выбор оптимальной характеристики:** Для каждого распределения существует своя наилучшая характеристика положения, обладающая минимальной дисперсией при заданном объеме выборки:
 - Для нормального распределения лучшей оценкой является выборочное среднее.

- Для распределения Коши и распределения Лапласа лучшей оценкой выступает медиана.
- Для распределения Пуассона при малых выборках оптимально выборочное среднее, а при больших ($n = 1000$) - полусумма квартилей (z_Q).
- Для равномерного распределения безоговорочно лучшей характеристикой является полусумма экстремальных элементов (z_R).

Список литературы

Бабахина, Софья Александровна. Практикум по математической статистике: учебное пособие / С. А. Бабахина, А. Н. Баженов; Санкт-Петербургский политехнический университет Петра Великого, Физико-механический институт, Высшая школа прикладной математики и вычислительной физики. - Санкт Петербург, 2026.

GITHUB

https://github.com/andreikurakin123/MatStat/tree/main/matstat_2_lab