

**Санкт-Петербургский политехнический университет
Петра Великого**

Физико-механический институт

Кафедра прикладной математики и информатики

Лабораторная работа №3

По дисциплине: “Математическая статистика”

Тема: «Боксплот Тьюки и анализ выбросов»

Выполнил студент гр. 5030102/30202:

Куракин А.В.

Преподаватель:

Баженов А.Н.

Санкт-Петербург

2025

Содержание

Формулировка задачи	2
Теоретическая часть	3
Программная реализация	5
Результаты	5
Обсуждение результатов	7
Выводы	8
Список литературы	8

Формулировка задачи

Цели работы:

1. Научиться применять боксплот Тьюки в обработке и анализе одномерных распределений.
2. Проанализировать, как размер выборки влияет на долю отсеиваемых аномальных значений.

Постановка задачи:

1. Сгенерировать выборки объемом $n = 20$ и $n = 100$ для пяти законов распределения: нормального, Коши, Лапласа, Пуассона и равномерного. Построить боксплоты Тьюки.
2. Опытным путем оценить долю выбросов: для каждого распределения и каждого объема сгенерировать выборку 1000 раз, после чего вычислить усредненную долю аномальных значений.

Теоретическая часть

Боксплот (box plot) — это графический инструмент описательной статистики, позволяющий в сжатом виде отобразить основные характеристики одномерного распределения (медиану, разброс, асимметрию) и локализовать выбросы.

Выбросы — это нетипичные для конкретной выборки экстремальные значения, которые существенно отдалены от основной массы наблюдений.

В основе построения графика лежат выборочные квантили.

Квантиль z_p — это значение, делящее распределение таким образом, что вероятность случайной величине оказаться меньше z_p равна p .

Алгоритм построения боксплота Тьюки:

1. Определяется нижний квартиль $Q_1 = z_{\frac{1}{4}}$.
2. Определяется верхний квартиль $Q_3 = z_{\frac{3}{4}}$.
3. Вычисляется медиана $Q_2 = z_{\frac{1}{2}}$.
4. Находится межквартильный размах (IQR) — мера рассеяния данных: $IQR = Q_3 - Q_1$.
5. Рассчитываются границы «усов» (допустимого диапазона типичных значений):
 - Нижняя граница: $X_1 = Q_1 - 1.5 \cdot IQR$
 - Верхняя граница: $X_2 = Q_3 + 1.5 \cdot IQR$

Точки, значения которых лежат вне интервала $[X_1, X_2]$, классифицируются как выбросы.

Вероятность того, что значение выйдет за границы усов, можно теоретически рассчитать через функцию распределения $F(x)$. Рассмотрим расчеты для изучаемых распределений:

1. Нормальное распределение $N(0, 1)$:

Квартили: $Q_1 \approx -0.6745$, $Q_3 \approx 0.6745$.

$IQR = 1.349$.

Границы: $\pm(0.6745 + 1.5 \cdot 1.349) = \pm 2.698$. Теоретическая доля выбросов: $P(|X| > 2.698) = 2 \cdot (1 - \Phi(2.698)) \approx 0.007(0.7\%)$.

2. Распределение Коши $C(0, 1)$:

Функция распределения: $F(x) = \frac{1}{\pi} \arctan(x) + 0.5$.

Квартили: $Q_1 = -1$, $Q_3 = 1$. $IQR = 2$.

Границы: $\pm(1 + 1.5 \cdot 2) = \pm 4$.

Теоретическая доля выбросов: $2 \cdot (1 - F(4)) = 1 - \frac{2}{\pi} \arctan(4) \approx 0.156(15.6\%)$.

3. Распределение Лапласа $L(0, \frac{1}{\sqrt{2}})$:

Квартили: $Q_1 = -\frac{\ln(2)}{\sqrt{2}}$, $Q_3 = \frac{\ln(2)}{\sqrt{2}}$. $IQR = \frac{2 \ln(2)}{\sqrt{2}}$

Верхняя граница $4 \frac{\ln(2)}{\sqrt{2}}$.

Теоретическая доля: $2 \cdot \left(0.5 \cdot e^{-\sqrt{2} \cdot 4 \frac{\ln(2)}{\sqrt{2}}}\right) = e^{-4 \ln(2)} = 2^{-4} = 0.0625(6.25\%)$.

4. Распределение Пуассона $P(5)$:

$Q_1 = 3$, $Q_3 = 6$. $IQR = 3$.

- Верхняя граница:

$6 + 1.5 \cdot 3 = 10.5$. Выбросами являются значения ≥ 11 .

- Теоретическая доля:

$P(X \geq 11) = 1 - P(X \leq 10) \approx 0.0137(1.37\%)$.

5. Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$:

Весь носитель распределения лежит внутри границ Тьюки. Выбросов не бывает, теоретическая доля строго равна 0.


Программная реализация

Для выполнения работы использовался язык программирования Python (библиотеки `numpy`, `scipy.stats`, `matplotlib`, `pandas`).

В ходе симуляции для объемов $n = 20, 100$ генерировалось по 1000 выборок. В каждой итерации с помощью функции `numpy.quantile` находились квартили Q_1 и Q_3 , вычислялся IQR и границы усов. Элементы, не попавшие в границы, маркировались как выбросы, и рассчитывалась их доля от n . Итоговый результат усреднялся по 1000 повторениям.

Для распределения Коши при визуализации было применено ограничение по оси Y, чтобы основной межквартильный размах оставался читаемым на фоне экстремально далеких выбросов.

Результаты






Рис 1.2 Боксплоты Тьюки для исследуемых распределений $n = 20$ и $n = 100$

Распределение	Доля выбросов ($n = 20$)	Доля выбросов ($n = 100$)	Теор доля
Нормальное $N(0, 1)$	0.024	0.010	0.007
Коши $C(0, 1)$	0.150	0.158	0.156
Лапласа $L\left(0, \frac{1}{\sqrt{2}}\right)$	0.074	0.065	0.0625
Пуассона $P(5)$	0.027	0.014	0.0137
Равномерное $U(-\sqrt{3}, \sqrt{3})$	0.003	0.000	0.000

Таблица 1. Средняя доля выбросов по результатам 1000 итераций.

Обсуждение результатов

Анализ графиков и полученной статистики позволяет сделать ряд важных наблюдений:

1. Визуальная специфика распределений:

- Нормальное и равномерное распределения обладают высокой симметрией. Однако у равномерного усы упираются в четкие границы, а выбросы отсутствуют.
- Распределение Коши визуально выделяется плотно сжатым «ящиком» и огромным облаком выбросов. Это связано с природой «тяжелых хвостов», при которых генерация экстремально больших по модулю чисел является нормой.
- Распределение Лапласа также генерирует заметно больше аномалий, чем нормальное, из-за более пологого спада плотности вероятности.
- Распределение Пуассона наглядно демонстрирует дискретность и правостороннюю асимметрию: все выбросы концентрируются в верхней части графика.

2. Соответствие эмпирических данных теории: Как видно из Таблицы 1, при увеличении объема выборки до $n = 100$ экспериментальная доля выбросов с высокой точностью приближается к вычисленному теоретическому значению.

3. Эффект малых выборок: При $n = 20$ во всех случаях, кроме Коши, наблюдается завышение реальной доли выбросов по сравнению с теорией (например, 0.024 вместо 0.007 для нормального распределения, и 0.003 вместо 0 для равномерного). Это объясняется тем, что на малых выборках оценка квантилей обладает высокой дисперсией. Межквартильный размах (IQR) часто оказывается

недооцененным, что приводит к сужению границ «усов» и ложному признанию нормальных значений выбросами. При $n = 100$ эта статистическая флуктуация сглаживается.

Выводы

1. **Информативность метода.** Боксплот Тьюки зарекомендовал себя как эффективный инструмент экспресс-анализа данных, позволяющий визуально оценивать не только медиану и дисперсию, но и форму распределения (тяжесть хвостов, симметричность).
2. **Роль формы распределения.** Доля отсекаемых выбросов напрямую зависит от теоретического закона. Использование жесткого правила « $1.5 \cdot IQR$ » для распределений с тяжелыми хвостами (Коши, Лаплас) приводит к тому, что 6-15% данных маркируются как аномалии, хотя они являются естественной частью процесса.
3. **Зависимость от объема данных.** Экспериментально доказано, что на малых выборках метод Тьюки склонен к гиперчувствительности из-за погрешностей в оценке квантилей. Для получения объективной картины и сходимости с теоретическими вероятностями требуются выборки достаточного объема.

Список литературы

1. Бабахина С. А., Баженов А. Н. Практикум по математической статистике: учебное пособие. — Санкт-Петербург: СПбПУ, 2026.