

**Санкт-Петербургский политехнический университет
Петра Великого**

Физико-механический институт

Кафедра прикладной математики и информатики

Лабораторная работа №3

По дисциплине: “Математическая статистика”

Тема: «»

Выполнил студент гр. 5030102/30202:

Куракин А.В.

Преподаватель:

Баженов Александр

Санкт-Петербург

2025

Содержание

Формулировка задачи	2
Теоретическая часть	3
Программная реализация	4
Результаты	5
Обсуждение результатов	9
Вывод	10
Список литературы	11

Формулировка задачи

Цели работы:

1. Сделать вывод о том, как мощность выборки влияет на приближение эмпирической функции к истинной функции распределения.
2. Сравнить два способа оценки плотности распределения: ядерные оценки и гистограммы.

Постановка задачи:

1. Сгенерировать псевдослучайные выборки объемов $n = 20, 60, 100$.
2. Построить графики эмпирической функции распределения (ЭФР) в сопоставлении с истинной (теоретической) функцией распределения.

3. Построить гистограммы и ядерные оценки плотности (на основе функции Гаусса) в сопоставлении с теоретической плотностью.

Примечание: Графики для непрерывных величин строятся на отрезке $[-4, 4]$, для дискретного распределения Пуассона — на отрезке $[6, 14]$.

Теоретическая часть

Эмпирическая функция распределения (ЭФР) — это ступенчатая функция $F_{n(x)}$, построенная по выборке, которая для каждого x показывает относительную частоту появления в выборке элементов, строго меньших x . Она является статистической оценкой теоретической функции распределения $F(x)$.

Ядерная оценка плотности — непараметрический метод восстановления неизвестной плотности вероятности по выборке. Расчет оценки в точке x ведется по формуле:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

где:

- n — объем выборки,
- x_i — элементы выборки,
- h — параметр сглаживания (ширина окна/полосы),
- $K(c \cdot)$ — ядерная функция. В данной работе применяется нормальное (Гауссово) ядро:

$$K\left(\frac{x - x_i}{h}\right) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x - x_i}{h}\right)^2}$$

Программная реализация

Используемый инструментарий:

- Язык программирования: Python 3.12.
- Библиотеки: `numpy` (массивы и вычисления), `scipy.stats` (статистические функции и генерация выборок), `matplotlib.pyplot` (отрисовка графиков).

Алгоритм построения: Для моделирования применялись методы модуля `scipy.stats` (`norm`, `cauchy`, `laplace`, `poisson`, `uniform`). Эмпирическая функция визуализировалась с помощью `plt.step` в режиме `where='post'` для обеспечения корректного вида «ступенек».

Оценка плотности строилась методом `scipy.stats.gaussian_kde()`, который по умолчанию использует Гауссово ядро и автоматически вычисляет оптимальную ширину полосы пропускания h (по правилу Скотта). На график также накладывалась нормированная гистограмма (`density=True`). Для распределения Пуассона теоретическая плотность выводилась точечно, так как вероятность определена только для целых чисел.

Результаты




Рис. 1. Графики ЭФР и оценок плотности для нормального распределения




Рис. 2. Графики ЭФР и оценок плотности для распределения Коши




Рис. 3. Графики ЭФР и оценок плотности для распределения Лапласа




Рис. 4. Графики ЭФР и оценок плотности для распределения Пуассона




Рис. 5. Графики ЭФР и оценок плотности для равномерного распределения

Обсуждение результатов

Анализ визуализированных данных позволяет детально рассмотреть поведение применяемых оценок:

1. Зависимость ЭФР от объема выборки: На малых объемах данных ($n = 20$) эмпирическая функция распределения характеризуется крупными скачками. Из-за высокой статистической погрешности кривая ЭФР может визуально отдаляться от теоретической функции. По мере роста выборки до $n = 100$ шаги становятся мелкими, а эмпирическая кривая начинает плотно огибать теоретическую. Это служит наглядной демонстрацией теоремы Гливенко-Кантелли, утверждающей равномерную сходимость ЭФР к истинной функции распределения.

2. Сопоставление методов оценки плотности:

- **Гистограммы** предоставляют лишь грубую, кусочно-постоянную модель распределения. Внешний вид гистограммы критически зависит от алгоритма выбора количества корзин (бинов), из-за чего она может скрывать локальные экстремумы или, наоборот, создавать ложные пики, особенно при $n = 20$.
- **Ядерная оценка** формирует математически гладкую кривую. При работе с непрерывными величинами (нормальный, равномерный законы, распределения Коши и Лапласа) использование Гауссова ядра дает значительно более естественный результат, который лучше аппроксимирует истинную плотность вероятности и нивелирует влияние случайных выбросов.

3. Специфика дискретных данных: Графики распределения Пуассона наглядно вскрывают фундаментальный недостаток применения непрерывных ядерных оценок к дискретным величинам. Функция `gaussian_kde` искусственно «размазывает» вероятности по всей числовой оси, формируя плотность вероятности в дробных точках, где случайная величина не может принимать значения в принципе. В этом частном случае классическая гистограмма или график функции масс (PMF) является единственно верным способом визуализации.

Вывод

В рамках лабораторной работы проведено успешное моделирование эмпирических функций и оценок плотности. Экспериментально подтверждено, что увеличение объема выборки влечет за собой повышение

точности аппроксимации теоретических законов распределения.

Сравнение инструментов анализа показало, что ядерное сглаживание превосходит гистограммы при работе с непрерывными случайными величинами, так как устраняет «ступенчатость» и формирует визуально понятную гладкую кривую. При этом доказано, что использование ядерных оценок для дискретных законов (на примере распределения Пуассона) методологически ошибочно, поскольку приводит к искажению физического смысла распределения вероятностей.

Список литературы

1. Бабахина С. А., Баженов А. Н. Практикум по математической статистике: учебное пособие. — Санкт-Петербург: СПбПУ, 2026.