

**Санкт-Петербургский политехнический университет  
Петра Великого**

**Физико-механический институт**

**Кафедра прикладной математики и информатики**

Лабораторная работа №4

По дисциплине: “Математическая статистика”

Тема: «Эмпирическая функция распределения и ядерные  
оценки плотности»

Выполнил студент гр. 5030102/30202:

Куракин А.В.

Преподаватель:

Баженов А.Н.

Санкт-Петербург

2025

# Содержание

|                              |    |
|------------------------------|----|
| Формулировка задачи .....    | 2  |
| Теоретическая часть .....    | 3  |
| Программная реализация ..... | 4  |
| Результаты .....             | 5  |
| Обсуждение результатов ..... | 9  |
| Вывод .....                  | 10 |
| Список литературы .....      | 11 |

## Формулировка задачи

### Цели работы:

1. Сделать вывод о том, как мощность выборки влияет на приближение эмпирической функции к истинной функции распределения.
2. Сравнить два способа оценки плотности распределения: ядерные оценки и гистограммы.

### Постановка задачи:

1. Сгенерировать псевдослучайные выборки объемов  $n = 20, 60, 100$ .
2. Построить графики эмпирической функции распределения (ЭФР) в сопоставлении с истинной (теоретической) функцией распределения.

3. Построить гистограммы и ядерные оценки плотности (на основе функции Гаусса) в сопоставлении с теоретической плотностью.

**Примечание:** Графики для непрерывных величин строятся на отрезке  $[-4, 4]$ , для дискретного распределения Пуассона — на отрезке  $[6, 14]$ .

## Теоретическая часть

**Эмпирическая функция распределения (ЭФР)** — это ступенчатая функция  $F_{n(x)}$ , построенная по выборке, которая для каждого  $x$  показывает относительную частоту появления в выборке элементов, строго меньших  $x$ . Она является статистической оценкой теоретической функции распределения  $F(x)$ .

**Ядерная оценка плотности** — непараметрический метод восстановления неизвестной плотности вероятности по выборке. Расчет оценки в точке  $x$  ведется по формуле:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

где:

- $n$  — объем выборки,
- $x_i$  — элементы выборки,
- $h$  — параметр сглаживания (ширина окна/полосы),
- $K(c \cdot)$  — ядерная функция. В данной работе применяется нормальное (Гауссово) ядро:

$$K\left(\frac{x - x_i}{h}\right) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x - x_i}{h}\right)^2}$$

# Программная реализация

## Используемый инструментарий:

- Язык программирования: Python 3.12.
- Библиотеки: `numpy` (массивы и вычисления), `scipy.stats` (статистические функции и генерация выборок), `matplotlib.pyplot` (отрисовка графиков).

**Алгоритм построения:** Для моделирования применялись методы модуля `scipy.stats` (`norm`, `cauchy`, `laplace`, `poisson`, `uniform`). Эмпирическая функция визуализировалась с помощью `plt.step` в режиме `where='post'` для обеспечения корректного вида «ступенек».

Оценка плотности строилась методом `scipy.stats.gaussian_kde()`, который по умолчанию использует Гауссово ядро и автоматически вычисляет оптимальную ширину полосы пропускания  $h$  (по правилу Скотта). На график также накладывалась нормированная гистограмма (`density=True`). Для распределения Пуассона теоретическая плотность выводилась точечно, так как вероятность определена только для целых чисел.

# Результаты




Рис. 1. Графики ЭФР и оценок плотности для нормального распределения




Рис. 2. Графики ЭФР и оценок плотности для распределения Коши




Рис. 3. Графики ЭФР и оценок плотности для распределения Лапласа




Рис. 4. Графики ЭФР и оценок плотности для распределения Пуассона




Рис. 5. Графики ЭФР и оценок плотности для равномерного распределения

## Обсуждение результатов

Анализ визуализированных данных позволяет детально рассмотреть поведение применяемых оценок:

**1. Зависимость ЭФР от объема выборки:** На малых объемах данных ( $n = 20$ ) эмпирическая функция распределения характеризуется крупными скачками. Из-за высокой статистической погрешности кривая ЭФР может визуально отдаляться от теоретической функции. По мере роста выборки до  $n = 100$  шаги становятся мелкими, а эмпирическая кривая начинает плотно огибать теоретическую. Это служит наглядной демонстрацией теоремы Гливенко-Кантелли, утверждающей равномерную сходимость ЭФР к истинной функции распределения.

## 2. Сопоставление методов оценки плотности:

- **Гистограммы** предоставляют лишь грубую, кусочно-постоянную модель распределения. Внешний вид гистограммы критически зависит от алгоритма выбора количества корзин (бинов), из-за чего она может скрывать локальные экстремумы или, наоборот, создавать ложные пики, особенно при  $n = 20$ .
- **Ядерная оценка** формирует математически гладкую кривую. При работе с непрерывными величинами (нормальный, равномерный законы, распределения Коши и Лапласа) использование Гауссова ядра дает значительно более естественный результат, который лучше аппроксимирует истинную плотность вероятности и нивелирует влияние случайных выбросов.

**3. Специфика дискретных данных:** Графики распределения Пуассона наглядно вскрывают фундаментальный недостаток применения непрерывных ядерных оценок к дискретным величинам. Функция `gaussian_kde` искусственно «размазывает» вероятности по всей числовой оси, формируя плотность вероятности в дробных точках, где случайная величина не может принимать значения в принципе. В этом частном случае классическая гистограмма или график функции масс (PMF) является единственно верным способом визуализации.

## Вывод

В рамках лабораторной работы проведено успешное моделирование эмпирических функций и оценок плотности. Экспериментально подтверждено, что увеличение объема выборки влечет за собой повышение

точности аппроксимации теоретических законов распределения.

Сравнение инструментов анализа показало, что ядерное сглаживание превосходит гистограммы при работе с непрерывными случайными величинами, так как устраняет «ступенчатость» и формирует визуально понятную гладкую кривую. При этом доказано, что использование ядерных оценок для дискретных законов (на примере распределения Пуассона) методологически ошибочно, поскольку приводит к искажению физического смысла распределения вероятностей.

## **Список литературы**

1. Бабахина С. А., Баженов А. Н. Практикум по математической статистике: учебное пособие. — Санкт-Петербург: СПбПУ, 2026.